

Sistema de Recomendacion Paralelo para E-Commerce

Plan de Trabajo por Entregables — 5 Miembros — Computacion Paralela y Distribuida

Profesor	Johansell Villalobos Cubillo	Curso	Computacion Paralela y Distribuida
Integrantes	5 miembros	Ponderacion	E1: 20% E2: 30% E3: 40% Presentacion: 10%
Duracion	6 semanas + presentacion	Tema	Sistema de Recomendacion Paralelo para E-Commerce

Descripcion del Proyecto

El proyecto consiste en disenar, implementar y evaluar un sistema de recomendacion personalizado para comercio electronico que aprovecha paralelismo multinucleo, aceleracion GPU y procesamiento distribuido para analizar grandes volúmenes de interacciones de usuarios y productos en tiempo real.

El objetivo es que el equipo comprenda como los conceptos de computacion paralela (speedup, eficiencia, sincronizacion, profiling) se traducen en aplicaciones practicas que afectan la vida diaria de millones de personas. Se busca construir un sistema que: analice en segundos miles de interacciones de usuarios, genere recomendaciones personalizadas en tiempo real, escale horizontalmente para picos de trafico (simulacion Black Friday) y demuestre como CPU, GPU y clusters distribuidos trabajan juntos en un servicio cotidiano.

Distribucion de Modulos por Miembro

Modulo	Titulo	Rol	Herramientas Clave
M1	Ingeniería de Datos y Pipeline de Ingestion	Data Engineer	Polars, Dask, cuDF, PyArrow, Parquet
M2	Analisis Exploratorio y Estadistico	Data Analyst	Dask, cuML, UMAP, Plotly, Scikit-Learn
M3	Modelo de Machine Learning y Recomendacion	ML Engineer	PyTorch, JAX, cuML, Optuna, Implicit
M4	Computacion Paralela y Analisis de Rendimiento	HPC Engineer	cProfile, Profiler, nvtop, pytest-benchmark
M5	Dashboard, Visualizacion e Integracion Final	Full-Stack / Integrador	Dash, Panel, Plotly, FastAPI, Docker

■ Entregable 1 — Fundamentos y Diseño del Proyecto

Semanas 1-2 | Peso en la nota final: 20%

■ Contexto y Objetivo de este Entregable

En esta primera entrega, el grupo presenta el diseño completo del sistema de recomendación paralelo para e-commerce. Cada miembro justifica el diseño de su módulo, identifica las herramientas a usar y elabora su parte del plan de trabajo. El entregable culmina en un documento IEEE unificado con introducción, marco teórico, arquitectura general del sistema y cronograma detallado.

Rubrica Oficial — Entrega 1

Criterio	Descripción	Puntaje
Claridad del problema	El problema está bien planteado, con contexto y motivación clara.	0 – 5
Objetivos específicos	Se definen objetivos claros, alcanzables y alineados con el problema.	0 – 5
Justificación técnica	Se explica por qué las herramientas o librerías fueron elegidas.	0 – 5
Plan de trabajo	El cronograma es realista y está alineado con los objetivos.	0 – 5
Documentación y presentación	El documento es ordenado, bien escrito y cumple con el formato requerido.	0 – 5
TOTAL		/ 25

Plan Detallado por Miembro — Entrega 1

■ ■ Miembro 1 — Ingeniería de Datos y Pipeline de Ingestión

Rol: Data Engineer | Módulo 1 de 5

Responsable de adquirir, limpiar y estructurar los datos de usuarios y productos usando herramientas distribuidas (Polars, Dask, cuDF). Construye el cimiento sobre el que trabajan todos los demás miembros.

Criterio (0-5 pts)	Descripción y Actividades	Entregable Concreto
Claridad del problema	Describir con precisión el problema de recomendación en e-commerce: volumen de datos, necesidad de paralelismo y caso de uso real (ej. simulación Black Friday).	<i>Dataset seleccionado (>1 GB), justificación de escala y script de descarga automatizado.</i>
Objetivos específicos	Definir los objetivos del pipeline ETL: tiempos de carga, throughput esperado y formato de salida (Parquet particionado por fecha/categoría).	<i>Al menos 3 objetivos medibles del pipeline de datos.</i>
Justificación técnica	Explicar por qué se elige Polars/Dask/cuDF sobre Pandas para el volumen de datos seleccionado. Comparar características clave de cada herramienta.	<i>Tabla comparativa Pandas vs Polars vs Dask con criterios técnicos.</i>

Plan de trabajo	Cronograma del Modulo 1 para las semanas 1-6, con hitos por entregable. Identificar dependencias con otros modulos (ej. M2 necesita datos limpios de M1).	Diagrama de Gantt o tabla de hitos del pipeline ETL.
Documentacion y presentacion	Seccion de Introduccion y Adquisicion de Datos del informe IEEE, redactada con terminologia de computacion paralela. README con instrucciones minimas de descarga.	Borrador de seccion IEEE + README inicial en GitLab.
Herramientas del modulo:	Polars, Dask, cuDF, PyArrow, Parquet, Kaggle API, HuggingFace datasets	

■ Miembro 2 — Analisis Exploratorio y Estadistico

Rol: Data Analyst | Modulo 2 de 5

Realiza el analisis exploratorio del dataset de interacciones de usuarios. Identifica patrones de comportamiento, segmenta usuarios con clustering paralelo y selecciona las variables mas relevantes para el recomendador.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Claridad del problema	Plantear las preguntas de negocio del analisis: patrones de compra, segmentos de usuarios, productos mas correlacionados. Motivar por que el EDA requiere herramientas paralelas (millones de registros).	Lista de al menos 5 preguntas analiticas con justificacion.
Objetivos especificos	Definir metricas del EDA: distribucion de interacciones, matriz de correlacion, numero optimo de clusters de usuarios y variables seleccionadas.	Al menos 4 objetivos estadisticos medibles.
Justificacion tecnica	Justificar el uso de clustering paralelo (cuML vs Scikit-Learn) y reduccion dimensional (UMAP/PCA). Explicar ventajas de Dask para EDA a gran escala.	Comparacion tecnica cuML vs Scikit-Learn para K-Means con GPU.
Plan de trabajo	Cronograma del Modulo 2: flujo desde datos limpios (M1) hasta variables seleccionadas para el modelo (M3). Hitos por semana.	Tabla de hitos con dependencia explicita en M1.
Documentacion y presentacion	Prototipo de 3 visualizaciones clave (distribucion de interacciones, heatmap de correlacion, scatter de clusters) con datos de muestra.	Notebook con graficas estaticas de muestra.

Herramientas del modulo:	Dask, Polars, Scikit-Learn, RAPIDS cuML, UMAP-learn, Plotly, Seaborn
--------------------------	--

■ Miembro 3 — Modelo de Machine Learning y Recomendacion

Rol: ML Engineer | Modulo 3 de 5

Disenha e implementa el nucleo del sistema de recomendacion: filtrado colaborativo, embeddings y redes neuronales entrenadas con GPU. Evalua con metricas de calidad (NDCG@K, MAP@K, Hit Rate).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Claridad del problema	Describir el problema de recomendacion como un problema de ranking personalizado. Explicar por que la escala requiere GPU: millones de pares usuario-producto y entrenamiento iterativo costoso.	Diagrama de arquitectura del sistema de recomendacion.

Objetivos especificos	Definir metricas objetivo: NDCG@10 >= X, MAP@10 >= Y, latencia de inferencia < Z ms. Especificar baseline (ALS/SVD) y modelo avanzado (NCF/Two-Tower).	Tabla de objetivos de calidad del modelo con valores esperados.
Justificacion tecnica	Comparar enfoques: filtrado colaborativo vs embeddings neurales vs Two-Tower. Justificar uso de PyTorch/JAX para entrenamiento GPU vs Scikit-Learn CPU.	Tabla comparativa de arquitecturas de recomendacion con pros/contras.
Plan de trabajo	Cronograma del Modulo 3: desde datos procesados (M1+M2) hasta modelo exportado para inferencia (M5). Hitos de entrenamiento por semana.	Secuencia: baseline -> tuning -> modelo final con fechas.
Documentacion y presentacion	Revision bibliografica de sistemas de recomendacion paralelos. Seccion de Marco Teorico del informe IEEE sobre ML distribuido.	Al menos 5 referencias academicas + borrador de marco teorico.
Herramientas del modulo:	PyTorch, JAX/Flax, Scikit-Learn, RAPIDS cuML, Optuna, Implicit	

■ Miembro 4 — Computacion Paralela y Analisis de Rendimiento

Rol: HPC Engineer | Modulo 4 de 5

Especialista en rendimiento. Mide speedup, eficiencia y escalabilidad en todas las etapas del pipeline. Identifica cuellos de botella y aplica optimizaciones (multiprocessing, Dask, CUDA profiling).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Claridad del problema	Definir el problema de rendimiento: cuales etapas del pipeline son los cuellos de botella y por que la computacion paralela es la solucion tecnica justificada para el volumen de datos seleccionado.	Diagrama del pipeline con estimacion de tiempo por etapa (secuencial).
Objetivos especificos	Definir metas de rendimiento: speedup esperado por etapa, eficiencia objetivo, throughput minimo del pipeline ETL y latencia maxima de inferencia.	Tabla de metas de rendimiento con valores numericos concretos.
Justificacion tecnica	Explicar que tecnicas de paralelismo aplican a cada etapa: data parallelism (ETL), model parallelism (ML), pipeline parallelism (inferencia). Justificar uso de Dask vs multiprocessing vs CUDA segun la etapa.	Mapa de decisiones: etapa -> tecnica de paralelismo -> herramienta.
Plan de trabajo	Cronograma del Modulo 4: mediciones baseline secuenciales en semana 1-2, benchmarks intermedios en semana 3-4, analisis completo en semana 5-6.	Plan de experimentos con metricas y configuraciones a probar.
Documentacion y presentacion	Configuracion reproducible del entorno de benchmarking: hardware, versiones de librerias, comandos de ejecucion, semillas fijas.	Script de medicion baseline + tabla de hardware utilizado.

Herramientas del modulo:	cProfile, line_profiler, PyTorch Profiler, nvttop, pytest-benchmark, time
--------------------------	---

■ ■ Miembro 5 — Dashboard, Visualizacion e Integracion Final

Rol: Full-Stack / Integrador | Modulo 5 de 5

Construye el dashboard interactivo (Dash/Panel + Plotly) para explorar recomendaciones y metricas. Integra todos los componentes en un flujo end-to-end reproducible y coordina el informe IEEE final.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Claridad del problema	Describir el problema de comunicacion de resultados: como presentar recomendaciones personalizadas y metricas de rendimiento de forma interactiva y comprensible para distintas audiencias.	Mockup del dashboard con descripcion de cada panel.
Objetivos especificos	Definir funcionalidades del dashboard: busqueda de usuario, top-N recomendaciones, grafica de speedup, comparacion de modelos, indicadores de latencia en tiempo real.	Lista de al menos 6 funcionalidades con criterio de aceptacion.
Justificacion tecnica	Comparar Dash vs Panel vs Streamlit para el caso de uso. Justificar la arquitectura de integracion: como el dashboard consume los resultados del modelo y del pipeline.	Diagrama de arquitectura de integracion de todos los modulos.
Plan de trabajo	Cronograma del Modulo 5: mockup estatico (E1), dashboard con EDA (E2), dashboard final integrado (E3). Hitos de integracion con otros modulos.	Diagrama de dependencias entre modulos con fechas de integracion.
Documentacion y presentacion	Estructura inicial del repositorio GitLab con carpetas definidas, README base y borrador de introduccion del informe IEEE del grupo.	Repositorio GitLab funcional + README con instrucciones de ejecucion.
Herramientas del modulo:	Dash, Panel, Plotly, FastAPI, Docker, GitLab CI, LaTeX/Word IEEE	

■ Entregable 2 — Implementacion Inicial y Validacion Parcial

Semanas 3-4 | Peso en la nota final: 30%

■ Contexto y Objetivo de este Entregable

En la segunda entrega se demuestra avance funcional concreto. El pipeline de datos debe estar operativo, el EDA completado sobre datos reales, el modelo baseline entrenado con primeras metricas, los primeros benchmarks de speedup medidos y el dashboard conectado al EDA. El codigo debe ser ejecutable desde el repositorio GitLab. Cada miembro defiende su modulo con resultados reales.

Rubrica Oficial — Entrega 2

Criterio	Descripcion	Puntaje
Claridad del problema	El problema esta bien planteado, con contexto y motivacion clara.	0 – 5
Objetivos especificos	Se definen objetivos claros, alcanzables y alineados con el problema.	0 – 5
Justificacion tecnica	Se explica por que las herramientas o librerias fueron elegidas.	0 – 5
Plan de trabajo	El cronograma es realista y esta alineado con los objetivos.	0 – 5
Documentacion y presentacion	El documento es ordenado, bien escrito y cumple con el formato requerido.	0 – 5
TOTAL		/ 25

Plan Detallado por Miembro — Entrega 2

■ ■ Miembro 1 — Ingeniería de Datos y Pipeline de Ingestion

Rol: Data Engineer | Modulo 1 de 5

Responsable de adquirir, limpiar y estructurar los datos de usuarios y productos usando herramientas distribuidas (Polars, Dask, cuDF). Construye el cimiento sobre el que trabajan todos los demas miembros.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Avance funcional	Pipeline ETL completamente operativo: descarga automatica, limpieza con Polars/cuDF, transformaciones y exportacion en Parquet particionado. Ejecutable desde el repositorio con un solo comando.	Script ejecutable + datos limpios en Parquet disponibles para M2 y M3.
Organizacion del codigo	Codigo modular con funciones documentadas en espanol: ingesta, limpieza, transformacion y exportacion separadas. Sin dependencias circulares.	Modulo src/pipeline_datos.py con docstrings y comentarios.
Validacion inicial	Comparativa de tiempo de carga: Pandas vs Polars vs Dask en el dataset completo. Reporte de throughput (registros/segundo) y uso de memoria.	Tabla de benchmarks ETL con al menos 3 configuraciones medidas.

Gestion de problemas	Documentar los obstaculos encontrados: archivos corruptos, tipos de datos inconsistentes, memoria insuficiente. Describir la solucion aplicada.	Seccion 'Problemas y Soluciones' en el informe con al menos 2 casos.
Documentacion y presentacion	Seccion de Adquisicion de Datos y Preprocesamiento del informe IEEE con descripcion del dataset, esquema de datos y metricas del pipeline.	Seccion IEEE completa + instrucciones de ejecucion del pipeline en README.
Herramientas del modulo:	Polars, Dask, cuDF, PyArrow, Parquet, Python multiprocessing	

■ Miembro 2 — Analisis Exploratorio y Estadistico

Rol: Data Analyst | Modulo 2 de 5

Realiza el analisis exploratorio del dataset de interacciones de usuarios. Identifica patrones de comportamiento, segmenta usuarios con clustering paralelo y selecciona las variables mas relevantes para el recomendador.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Avance funcional	EDA completo sobre el dataset real: estadisticas descriptivas por segmento, matriz de correlacion, distribucion de interacciones y segmentacion preliminar de usuarios con K-Means paralelo.	Notebook de EDA ejecutable con visualizaciones sobre datos reales.
Organizacion del codigo	Funciones reutilizables para estadisticas, clustering y visualizacion. Parametros configurables (numero de clusters, variables a analizar).	Modulo src/analisis_eda.py con funciones documentadas.
Validacion inicial	Resultados del clustering: silhouette score, numero de clusters optimo (metodo del codo) y descripcion de cada segmento de usuario identificado.	Grafica del metodo del codo + tabla descriptiva de segmentos.
Gestion de problemas	Documentar problemas de datos: variables con alta cardinalidad, sesgo en distribuciones, cold-start problem. Estrategias aplicadas.	Seccion de calidad de datos en el informe con soluciones documentadas.
Documentacion y presentacion	Seccion de Analisis Exploratorio del informe IEEE con hallazgos clave, graficas interpretadas y justificacion de variables seleccionadas.	Seccion IEEE + al menos 5 visualizaciones con interpretacion.

Herramientas del modulo: Dask, Polars, Scikit-Learn, RAPIDS cuML, UMAP-learn, Plotly, Seaborn

■ Miembro 3 — Modelo de Machine Learning y Recomendacion

Rol: ML Engineer | Modulo 3 de 5

Disenha e implementa el nucleo del sistema de recomendacion: filtrado colaborativo, embeddings y redes neuronales entrenadas con GPU. Evalua con metricas de calidad (NDCG@K, MAP@K, Hit Rate).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Avance funcional	Modelo baseline funcional (ALS o SVD con filtrado colaborativo) entrenado sobre el dataset completo y evaluado con NDCG@10 y MAP@10. Primer entrenamiento del modelo neural en GPU.	Notebook con metricas del baseline + primeras epocas del modelo neural.

Organizacion del codigo	Clases modulares para cada arquitectura: BaselineModel, NeuralModel. Separacion clara entre entrenamiento, validacion e inferencia.	Modulo src/modelo_recomendacion.py con clases documentadas.
Validacion inicial	Comparacion preliminar: baseline vs modelo neural en NDCG@10. Curvas de aprendizaje (loss vs epocas). Tiempo de entrenamiento GPU vs CPU.	Tabla comparativa baseline/neural + graficas de convergencia.
Gestion de problemas	Documentar problemas de entrenamiento: overfitting, convergencia lenta, problemas de memoria GPU. Estrategias aplicadas (dropout, learning rate schedule).	Seccion de desafios de entrenamiento en el informe con soluciones.
Documentacion y presentacion	Seccion de Modelado del informe IEEE: descripcion de arquitecturas, funcion de perdida, metricas de evaluacion y configuracion de entrenamiento.	Seccion IEEE de modelado + descripcion de hiperparametros usados.
Herramientas del modulo:	PyTorch, JAX/Flax, Scikit-Learn, RAPIDS cuML, Optuna, Implicit	

■ Miembro 4 — Computacion Paralela y Analisis de Rendimiento

Rol: HPC Engineer | Modulo 4 de 5

Especialista en rendimiento. Mide speedup, eficiencia y escalabilidad en todas las etapas del pipeline. Identifica cuellos de botella y aplica optimizaciones (multiprocessing, Dask, CUDA profiling).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Avance funcional	Primeras mediciones de speedup en el pipeline ETL (M1): secuencial vs paralelo con 2, 4 y 8 workers. Profiling del entrenamiento ML (M3) con identificacion de las operaciones mas costosas.	Graficas de speedup del ETL + reporte de profiling del modelo.
Organizacion del codigo	Scripts de benchmarking reutilizables con parametros configurables (numero de workers, tamano de datos). Resultados guardados en CSV.	Modulo src/benchmarks.py + carpeta resultados/ con CSVs.
Validacion inicial	Tabla de speedup por etapa del pipeline (ETL, clustering, entrenamiento). Identificacion documentada de los 3 principales cuellos de botella.	Tabla speedup + diagrama de flame graph o profiling report.
Gestion de problemas	Documentar problemas de medicion: variabilidad entre ejecuciones, interferencia de procesos del sistema. Estrategia de promedio y warm-up.	Protocolo de medicion documentado con numero de repeticiones y warm-up.
Documentacion y presentacion	Seccion preliminar de Analisis de Rendimiento en el informe IEEE: configuracion experimental, metricas medidas y primeros resultados.	Borrador de seccion IEEE de rendimiento con metodologia de benchmarking.
Herramientas del modulo:	cProfile, line_profiler, PyTorch Profiler, nvtop, pytest-benchmark, Jupyter	

■ ■ Miembro 5 — Dashboard, Visualizacion e Integracion Final

Rol: Full-Stack / Integrador | Modulo 5 de 5

Construye el dashboard interactivo (Dash/Panel + Plotly) para explorar recomendaciones y metricas. Integra todos los componentes en un flujo end-to-end reproducible y coordina el informe IEEE final.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Avance funcional	Dashboard funcional conectado a los resultados del EDA (M2): visualiza segmentos de usuarios, distribucion de interacciones y top productos. Pipeline integrado E1+E2 ejecutable con un solo comando.	App Dash/Panel corriendo localmente con datos del EDA.
Organizacion del codigo	Estructura de carpetas establecida: dashboard/, src/, notebooks/, datos/, resultados/. Makefile o docker-compose para ejecucion reproducible.	Repositorio GitLab organizado + Makefile funcional.
Validacion inicial	Demo funcional del dashboard con al menos 3 vistas interactivas: exploracion de usuarios, top-N recomendaciones preliminares y grafica de speedup del ETL.	Capturas de pantalla del dashboard + video de demo de 2 minutos.
Gestion de problemas	Documentar problemas de integracion entre modulos: incompatibilidades de formato de datos, dependencias de versiones. Soluciones aplicadas.	Seccion de integracion en el informe con problemas y soluciones.
Documentacion y presentacion	Secciones de Metodologia y Diseno del Pipeline del informe IEEE. Instrucciones completas de instalacion y ejecucion en README.	README detallado + secciones IEEE de metodologia completadas.
Herramientas del modulo:	Dash, Panel, Plotly, Docker, Make, GitLab, FastAPI	

■ Entregable 3 — Proyecto Final Completo

Semanas 5-6 | Peso en la nota final: 40%

■ Contexto y Objetivo de este Entregable

La entrega final presenta el sistema completamente integrado y optimizado. El pipeline ETL alcanza los objetivos de escalabilidad definidos en E1, el modelo neural supera al baseline en NDCG@10, el analisis de rendimiento reporta speedup y eficiencia en todas las etapas, y el dashboard interactivo genera recomendaciones personalizadas en tiempo real. El informe IEEE completo y el repositorio GitLab documentado son los entregables principales.

Rubrica Oficial — Entrega 3

Criterio	Descripcion	Puntaje
Claridad del problema	El problema esta bien planteado, con contexto y motivacion clara.	0 – 5
Objetivos especificos	Se definen objetivos claros, alcanzables y alineados con el problema.	0 – 5
Justificacion tecnica	Se explica por que las herramientas o librerias fueron elegidas.	0 – 5
Plan de trabajo	El cronograma es realista y esta alineado con los objetivos.	0 – 5
Documentacion y presentacion	El documento es ordenado, bien escrito y cumple con el formato requerido.	0 – 5
TOTAL		/ 25

Plan Detallado por Miembro — Entrega 3

■ ■ Miembro 1 — Ingeniería de Datos y Pipeline de Ingestion

Rol: Data Engineer | Modulo 1 de 5

Responsable de adquirir, limpiar y estructurar los datos de usuarios y productos usando herramientas distribuidas (Polars, Dask, cuDF). Construye el cimientio sobre el que trabajan todos los demas miembros.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Funcionalidad del proyecto	Pipeline ETL final optimizado con carga incremental y soporte para actualizaciones en tiempo real. Ejecutable de principio a fin en menos del tiempo objetivo definido en E1.	<i>Pipeline completo ejecutable + tiempo de ejecucion documentado.</i>
Eficiencia o escalabilidad	Benchmark de escalabilidad fuerte: mismo dataset con 1, 2, 4 y 8 workers. Benchmark de escalabilidad debil: aumentar datos proporcionalmente a workers.	<i>Graficas de escalabilidad fuerte y debil del pipeline ETL.</i>
Analisis de resultados	Comparativa final: Polars vs Dask vs cuDF en tiempos de carga, limpieza y transformacion. Recomendacion justificada de herramienta.	<i>Tabla comparativa final con speedup, eficiencia y throughput por herramienta.</i>

Codigo limpio y reproducible	Pipeline ejecutable desde cero con un solo comando. Semillas fijas, versiones de librerias en requirements.txt, datos de muestra incluidos.	requirements.txt + instrucciones de reproduccion en README.
Informe final	Seccion completa de Adquisicion y Preprocesamiento en el informe IEEE: descripcion del dataset, arquitectura del pipeline, resultados y lecciones.	Seccion IEEE final revisada + conclusiones del modulo de datos.
Herramientas del modulo:	Polars, Dask, cuDF, Dask-cuDF, PyArrow, Parquet	

■ Miembro 2 — Analisis Exploratorio y Estadistico

Rol: Data Analyst | Modulo 2 de 5

Realiza el analisis exploratorio del dataset de interacciones de usuarios. Identifica patrones de comportamiento, segmenta usuarios con clustering paralelo y selecciona las variables mas relevantes para el recomendador.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Funcionalidad del proyecto	Clustering final con cuML GPU vs Scikit-Learn CPU: K-Means y/o DBSCAN sobre el dataset completo. Reduccion dimensional con UMAP para visualizacion 2D de usuarios y productos.	Notebook final con clusters etiquetados y visualizacion UMAP interactiva.
Eficiencia o escalabilidad	Speedup GPU vs CPU en K-Means para distintos tamanos de datos: 100K, 1M y 10M registros. Analisis del umbral donde GPU supera a CPU.	Grafica speedup GPU/CPU vs tamano de datos para clustering.
Analisis de resultados	Interpretacion de cada segmento de usuario: patron de compra, productos preferidos, frecuencia de interaccion. Implicaciones para el sistema de recomendacion.	Tabla descriptiva de segmentos + recomendaciones estrategicas.
Codigo limpio y reproducible	Funciones parametrizables de EDA y clustering. Configuracion de semillas para reproducibilidad. Resultados exportados en CSV/Parquet.	Modulo src/analisis_eda.py listo para uso por M3 y M5.
Informe final	Seccion de Analisis Exploratorio del informe IEEE con hallazgos, graficas interpretadas, resultados de clustering y variables finales seleccionadas.	Seccion IEEE final + al menos 8 visualizaciones con interpretacion.

Herramientas del modulo:	RAPIDS cuML, Scikit-Learn, UMAP-learn, Dask, Plotly
--------------------------	---

■ Miembro 3 — Modelo de Machine Learning y Recomendacion

Rol: ML Engineer | Modulo 3 de 5

Disenja e implementa el nucleo del sistema de recomendacion: filtrado colaborativo, embeddings y redes neuronales entrenadas con GPU. Evalua con metricas de calidad (NDCG@K, MAP@K, Hit Rate).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Funcionalidad del proyecto	Modelo final optimizado (NCF o Two-Tower) entrenado con los mejores hiperparametros. Inferencia en batch sobre el dataset completo generando top-10 recomendaciones para cada usuario.	Modelo guardado + script de inferencia batch funcional.

Eficiencia o escalabilidad	Benchmark de entrenamiento: GPU vs CPU en tiempo por epoca. Escalabilidad del batch de inferencia: latencia vs tamaño del batch. Uso de VRAM documentado durante entrenamiento.	<i>Graficas tiempo/epoca GPU vs CPU + latencia vs batch size.</i>
Analisis de resultados	Comparativa final: baseline ALS vs modelo neural en NDCG@10, MAP@10, Hit Rate@10 y diversidad de recomendaciones. Analisis de errores: casos donde el modelo falla y por que.	<i>Tabla comparativa de modelos + analisis de errores documentado.</i>
Codigo limpio y reproducible	Script de entrenamiento con argumentos por linea de comandos. Modelo exportado en formato estandar (ONNX o TorchScript) para inferencia.	<i>Script train.py + modelo exportado + instrucciones de inferencia.</i>
Informe final	Secciones de Modelado y Resultados del informe IEEE: arquitecturas, metricas de calidad, comparativa de modelos y conclusiones del recomendador.	<i>Secciones IEEE finales de modelado y resultados del sistema.</i>
Herramientas del modulo:	PyTorch, JAX, RAPIDS cuML, Optuna, ONNX, TorchScript	

■ Miembro 4 — Computacion Paralela y Analisis de Rendimiento

Rol: HPC Engineer | Modulo 4 de 5

Especialista en rendimiento. Mide speedup, eficiencia y escalabilidad en todas las etapas del pipeline. Identifica cuellos de botella y aplica optimizaciones (multiprocessing, Dask, CUDA profiling).

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Funcionalidad del proyecto	Analisis de rendimiento completo del sistema integrado: ETL, clustering, entrenamiento e inferencia. Identificacion y documentacion de todos los cuellos de botella con estrategias de optimizacion aplicadas.	<i>Reporte de rendimiento completo con antes/despues de optimizaciones.</i>
Eficiencia o escalabilidad	Speedup y eficiencia por etapa del pipeline. Escalabilidad fuerte y debil del sistema completo. Analisis de balance de carga y costos de comunicacion en procesamiento distribuido.	<i>Graficas de speedup, eficiencia y escalabilidad para todo el sistema.</i>
Analisis de resultados	Identificacion de las 3 principales mejoras aplicadas y su impacto cuantitativo en el rendimiento. Discusion de limitaciones y trabajo futuro para mayor escalabilidad.	<i>Tabla de mejoras con impacto medido antes/despues.</i>
Codigo limpio y reproducible	Suite de benchmarks automatizada: un solo script ejecuta todas las mediciones y genera las graficas del informe. Configuracion de hardware documentada.	<i>Script benchmark_completo.py + graficas generadas automaticamente.</i>
Informe final	Seccion completa de Analisis de Rendimiento del informe IEEE: metodologia, configuracion experimental, todas las metricas y discusion critica de resultados.	<i>Seccion IEEE de rendimiento completa y revisada.</i>
Herramientas del modulo:	cProfile, PyTorch Profiler, nvtop, Dask Dashboard, CUDA, pytest-benchmark	

■ ■ Miembro 5 — Dashboard, Visualizacion e Integracion Final

Rol: Full-Stack / Integrador | Modulo 5 de 5

Construye el dashboard interactivo (Dash/Panel + Plotly) para explorar recomendaciones y metricas. Integra todos los componentes en un flujo end-to-end reproducible y coordina el informe IEEE final.

Criterio (0-5 pts)	Descripcion y Actividades	Entregable Concreto
Funcionalidad del proyecto	Dashboard final completamente integrado: recomendaciones en tiempo real para cualquier usuario, visualizacion de metricas de rendimiento, comparativa de modelos y exploracion del EDA. Desplegable con docker-compose.	Dashboard final + video de demo de 5 minutos mostrando todas las funcionalidades.
Eficiencia o escalabilidad	Latencia de respuesta del dashboard medida: tiempo desde solicitud hasta visualizacion de recomendaciones. Prueba de carga simulando multiples usuarios concurrentes (simulacion pico Black Friday).	Reporte de latencia del dashboard + resultado de prueba de carga.
Analisis de resultados	Informe IEEE completo y unificado con todas las secciones de los 5 modulos. Conclusiones generales del proyecto: que funciona, que no y que se aprendio.	Informe IEEE final completo revisado por todos los miembros.
Codigo limpio y reproducible	Repositorio GitLab completo: codigo fuente, notebooks, datos de muestra, resultados de benchmarks y dashboard. Reproducible desde cero con README.	Repositorio GitLab final + instrucciones de reproduccion completa.
Informe final	Coordinacion de la presentacion final del grupo: slides, distribucion de tiempo por modulo y preparacion de la demo en vivo.	Slides de presentacion + guion de la demo del sistema.

Herramientas del modulo:

Dash, Panel, Plotly, FastAPI, Docker, docker-compose, GitLab