



---

# **Proyecto del Curso: Exploración de Herramientas Paralelas y Distribuidas para el Análisis de Datos en Python**

---

**PROFESOR**

Johansell Villalobos Cubillo

2026-06-10

# Índice

|                                                                                                                       |          |
|-----------------------------------------------------------------------------------------------------------------------|----------|
| <b>1 Proyecto del Curso: Exploración de Herramientas Paralelas y Distribuidas para el Análisis de Datos en Python</b> | <b>1</b> |
| 1.1 Objetivo . . . . .                                                                                                | 1        |
| 1.2 Descripción . . . . .                                                                                             | 1        |
| 1.3 Evaluación . . . . .                                                                                              | 8        |
| 1.4 Notas adicionales . . . . .                                                                                       | 9        |
| 1.4.1 Posibles fuentes de datos >1GB . . . . .                                                                        | 9        |
| 1.4.2 Plantillas para informes IEEE . . . . .                                                                         | 10       |

## 1. Proyecto del Curso: Exploración de Herramientas Paralelas y Distribuidas para el Análisis de Datos en Python

### 1.1. Objetivo

El objetivo de este proyecto es que los estudiantes diseñen, implementen y evalúen una solución moderna de ciencia de datos, aprendizaje automático, inteligencia artificial o computación científica utilizando herramientas de computación paralela y distribuida en Python.

A través del desarrollo de un proyecto aplicado, los estudiantes deberán demostrar competencias en procesamiento de datos a gran escala, análisis estadístico, modelado computacional, visualización de resultados y evaluación del rendimiento de sistemas paralelos y distribuidos.

Se busca que los estudiantes desarrollen una comprensión integral de los desafíos asociados al procesamiento de grandes volúmenes de datos y al uso eficiente de recursos computacionales modernos, incluyendo procesadores multinúcleo, aceleradores GPU y sistemas distribuidos.

### 1.2. Descripción

El proyecto consistirá en el diseño, implementación y evaluación de un flujo de trabajo completo de análisis de datos, Machine Learning, Inteligencia Artificial o Computación Científica utilizando herramientas modernas del ecosistema Python.

Cada grupo (máximo 6 integrantes) deberá seleccionar un problema de interés científico, industrial o social cuya complejidad computacional justifique el uso de técnicas de paralelismo, aceleración mediante GPU o procesamiento distribuido.

La temática del proyecto es abierta y podrá abarcar áreas como:

- Ciencia de datos a gran escala.
- Machine Learning.

- Inteligencia Artificial.
- Procesamiento de imágenes o video.
- Procesamiento de lenguaje natural.
- Sistemas de recomendación.
- Bioinformática.
- Computación científica.
- Series temporales.
- Datos geoespaciales.
- Finanzas computacionales.
- Ciencias ambientales y climáticas.

Todos los proyectos deberán implementar obligatoriamente las siguientes etapas.

### **1. Adquisición y Gestión de Datos**

Selección de un conjunto de datos real de tamaño significativo.

Se recomienda utilizar conjuntos de datos de varios gigabytes, millones de registros o colecciones masivas de imágenes, documentos, series temporales o datos geoespaciales.

Los estudiantes deberán justificar por qué la escala del problema requiere el uso de herramientas paralelas o distribuidas.

### **2. Preprocesamiento Paralelo o Distribuido**

Los estudiantes deberán utilizar herramientas modernas para el procesamiento eficiente de datos.  
Herramientas sugeridas:

- Dask
- Polars
- cuDF
- Dask-cuDF
- PyArrow

Ejemplos de actividades:

---

- Limpieza de datos.
- Integración de múltiples fuentes.
- Agregaciones.
- Transformaciones.
- Construcción de variables derivadas.
- Procesamiento geoespacial.
- Procesamiento temporal.

### 3. Análisis Exploratorio y Estadístico

Se deberá realizar un análisis exploratorio riguroso utilizando herramientas estadísticas apropiadas.

Herramientas sugeridas:

- Scikit-Learn
- PyMC
- NumPyro
- StatsModels

Algunas actividades posibles incluyen:

- Estadística descriptiva.
- Inferencia bayesiana.
- Cuantificación de incertidumbre.
- Clustering.
- Reducción de dimensionalidad.
- Selección de variables.

#### 4. Modelado de Machine Learning o Inteligencia Artificial

Todos los proyectos deberán incorporar al menos un componente de modelado predictivo o aprendizaje automático.

Herramientas sugeridas:

- Scikit-Learn
- RAPIDS cuML
- PyTorch
- JAX

Ejemplos de modelos:

- Random Forest.
- Gradient Boosting.
- XGBoost.
- Redes neuronales profundas.
- Autoencoders.
- Transformers.
- Vision Transformers.
- Arquitecturas híbridas.

#### 5. Postprocesamiento y Análisis de Resultados

Los resultados obtenidos deberán ser analizados utilizando métricas apropiadas para el problema seleccionado.

Se espera incluir:

- Métricas de desempeño.
  - Análisis de errores.
  - Interpretabilidad.
  - Cuantificación de incertidumbre.
  - Comparación entre metodologías.
-

## 6. Visualización y Difusión de Resultados

Todos los proyectos deberán incluir una plataforma de visualización interactiva para comunicar resultados.

Herramientas sugeridas:

- Plotly
- Dash
- Bokeh
- Panel

El dashboard deberá permitir explorar los resultados obtenidos, visualizar métricas relevantes y comunicar los hallazgos principales del proyecto.

## Requisitos de Computación Paralela y Distribuida

Cada proyecto deberá incorporar al menos una de las siguientes características:

- Paralelismo multinúcleo.
- Procesamiento distribuido de datos.
- Computación acelerada mediante GPU.
- Machine Learning distribuido.
- Deep Learning distribuido.
- Inferencia distribuida.
- Pipelines distribuidos de procesamiento.

Los estudiantes deberán justificar técnicamente las decisiones de diseño adoptadas y explicar por qué las herramientas seleccionadas son apropiadas para el problema planteado.

### **Análisis de Rendimiento**

Dado que este es un curso de Computación Paralela y Distribuida, todos los proyectos deberán incluir una evaluación experimental del rendimiento computacional de la solución propuesta.

Dependiendo de la naturaleza del proyecto, se espera reportar métricas como:

- Tiempo de ejecución.
- Speedup.
- Eficiencia.
- Escalabilidad fuerte.
- Escalabilidad débil.
- Throughput.
- Uso de memoria.
- Utilización de GPU.
- Costos de comunicación.
- Balance de carga.

Los estudiantes deberán identificar los principales cuellos de botella de la aplicación y discutir posibles estrategias de optimización.

### **Entregables**

#### **1. Informe técnico en formato IEEE**

El informe deberá incluir:

- Introducción.
- Trabajo relacionado.
- Marco teórico.
- Metodología.
- Diseño del pipeline computacional.
- Configuración experimental.
- Resultados.
- Análisis de rendimiento.

- Conclusiones.

## 2. Repositorio GitLab

El repositorio deberá contener:

- Código fuente.
- Scripts de ejecución.
- Notebooks utilizados.
- README con instrucciones de reproducción.
- Datos o enlaces a los datos utilizados.
- Rpyesultados experimentales.
- Dashboard desarrollado.

La evaluación del proyecto priorizará la calidad del diseño computacional, la correcta utilización de herramientas modernas de computación paralela y distribuida, la reproducibilidad de los experimentos y el análisis crítico del rendimiento obtenido.

Este proyecto permitirá a los estudiantes aplicar los conceptos aprendidos en clase, desarrollar pensamiento crítico sobre herramientas modernas en Python, y fortalecer habilidades de escritura científica y documentación de código en un contexto profesional.



### 1.3. Evaluación

#### Rúbrica de Evaluación - Entrega 1: Fundamentos y Diseño del Proyecto

| Criterio                     | Descripción                                                               | Puntaje    |
|------------------------------|---------------------------------------------------------------------------|------------|
| Claridad del problema        | El problema está bien planteado, con contexto y motivación clara.         | 0–5        |
| Objetivos específicos        | Se definen objetivos claros, alcanzables y alineados con el problema.     | 0–5        |
| Justificación técnica        | Se explica por qué las herramientas o librerías fueron elegidas.          | 0–5        |
| Plan de trabajo              | El cronograma es realista y está alineado con los objetivos.              | 0–5        |
| Documentación y presentación | El documento es ordenado, bien escrito y cumple con el formato requerido. | 0–5        |
| <b>Total</b>                 |                                                                           | <b>/25</b> |

#### Rúbrica de Evaluación - Entrega 2: Implementación Inicial y Validación Parcial

| Criterio                     | Descripción                                                                | Puntaje    |
|------------------------------|----------------------------------------------------------------------------|------------|
| Avance funcional             | Se demuestra código que realiza parte del objetivo general.                | 0–5        |
| Organización del código      | Código modular, legible, con comentarios y buenas prácticas.               | 0–5        |
| Validación inicial           | Resultados preliminares o pruebas que justifican el progreso.              | 0–5        |
| Gestión de problemas         | Se identifican obstáculos y se documenta cómo se abordaron.                | 0–5        |
| Documentación y presentación | Informe conciso, claro, con instrucciones mínimas para ejecutar el código. | 0–5        |
| <b>Total</b>                 |                                                                            | <b>/25</b> |

**Rúbrica de Evaluación - Entrega 3: Proyecto Final Completo**

| <b>Criterio</b>              | <b>Descripción</b>                                                         | <b>Puntaje</b> |
|------------------------------|----------------------------------------------------------------------------|----------------|
| Funcionalidad del proyecto   | El proyecto cumple los objetivos propuestos, produce resultados correctos. | 0–5            |
| Eficiencia o escalabilidad   | Se analiza el rendimiento o se justifica el diseño implementado.           | 0–5            |
| Análisis de resultados       | Resultados interpretados con criterios técnicos, comparación si aplica.    | 0–5            |
| Código limpio y reproducible | Código bien estructurado, con instrucciones claras para ejecutarlo.        | 0–5            |
| Informe final                | Documento completo, bien argumentado, con conclusiones y lecciones.        | 0–5            |
| <b>Total</b>                 |                                                                            | <b>/25</b>     |

**Ponderación**

| <b>Entrega</b> | <b>Descripción</b>                          | <b>Peso</b> |
|----------------|---------------------------------------------|-------------|
| Entrega 1      | Fundamentos y diseño del proyecto           | 20 %        |
| Entrega 2      | Implementación inicial y validación parcial | 30 %        |
| Entrega 3      | Proyecto final completo                     | 40 %        |
| Entrega 4      | Presentación                                | 10 %        |

**1.4. Notas adicionales**

El proyecto está diseñado para ser flexible y adaptable al nivel de experiencia del estudiante. Se fomentará la creatividad, el aprendizaje autodirigido y el pensamiento crítico sobre las ventajas y desventajas de las distintas herramientas paralelas y distribuidas en el ecosistema Python.

**1.4.1. Posibles fuentes de datos >1GB**

- Kaggle
- HuggingFace
- ERA5 atmospheric variable dataset
- CHRS precipitation dataset

#### **1.4.2. Plantillas para informes IEEE**

- $\text{\LaTeX}$
- Word